

Optimización de Modelos de **Machine Learning**

Programación para la Ciencia de Datos — SCY1101 · Duoc UC

Dayana Vega

Modelado Supervisado

Stanley Joseph

Evaluación de Modelos

Encar Portillo

Optimización de HPs

Dataset y Segmentación de Clientes (K-Means)

El Dataset

15.750

registros de clientes

21

variables disponibles

51%

clase Anual (target=1)

80/20

split Train / Test

Segmentación K-Means (K=3)

Clúster 0

Activos

~11 compras / 3m

Clúster 1

Regulares

~7 compras / 3m

Clúster 2

Esporádicos ⚠

~3 compras / 3m

Clúster 2 es la oportunidad clave: visitan la plataforma igual que los demás pero compran 3.6× menos. Un estímulo pequeño puede moverlos a Regulares.

Modelos Supervisados Base: RF vs. Regresión Logística



Random Forest

ROC-AUC 0.6262

CV Accuracy 0.5654 ± 0.0069

F1 Clase 0 0.55

F1 Clase 1 0.59

Falsos Neg. 646 ⚠

✓ Modelo seleccionado

Regresión Logística

ROC-AUC 0.5058

CV Accuracy 0.5032 ± 0.0118


F1 Clase 0 0.38

F1 Clase 1 0.60

Falsos Pos. +1.000 ⚠

✗ Solo como benchmark

Pipeline Completo del Proyecto



Reproducibilidad garantizada: random_state=42 en todos los experimentos · Partición estratificada · 5-fold cross-validation

Evaluación Técnica: Métricas y Comparación

0.6262

ROC-AUC
Random Forest

0.5058

ROC-AUC
Reg. Logística

0.0069

Desv. Est. CV
(alta estabilidad RF)

646

Falsos Negativos
baseline RF

Interpretación de Resultados

- Random Forest supera al azar con ROC-AUC 0.6262; Regresión Logística opera cerca del azar (0.5058).
- La baja desviación estándar del RF en CV (0.0069) confirma estabilidad: el modelo no depende del fold elegido.
- 646 Falsos Negativos con umbral 0.50 representan oportunidades de upgrade no detectadas → problema central a resolver.
- Regresión Logística genera +1.000 Falsos Positivos: inviable como herramienta de campaña con costo de contacto real.

Matrices de Confusión: El Costo Comercial de los Errores

Random Forest — Umbral 0.50

	Pred: 0	Pred: 1
Real: 0	814	730
Real: 1	646 ⚠	960

Regresión Logística — Umbral 0.50

	Pred: 0	Pred: 1
Real: 0	459	1085 ⚠
Real: 1	465	1141

RF: 646 oportunidades perdidas. LR: +1.085 contactos inútiles con alto costo. La optimización debe reducir los Falsos Negativos de RF sin disparar Falsos Positivos.

Evaluación de Modelos de Regresión — Predicción de `total_spent`

Pregunta experimental: ¿es posible predecir el gasto total de un cliente (`total_spent`) a partir del resto de variables del dataset? Se comparan `LinearRegression` y `RandomForestRegressor` ($n=300$) con métricas RMSE y R^2 .

RandomForestRegressor ($n_estimators=300$)

RMSE

262.29

Menor error — mejor modelo

 R^2 **0.0481**Ligeramente > 0 : capta algo de señal

✓ Mejor baseline de regresión

LinearRegression

RMSE

269.16


+6.87 puntos vs RF

 R^2 **-0.0024** < 0 : peor que predecir la media✗ R^2 negativo: no agrega valor predictivo

Conclusión: aunque RF supera a LR, el $R^2 \approx 0$ en ambos modelos confirma que `total_spent` no puede predecirse con las variables actuales. El gasto depende de factores externos no capturados en el dataset. Esto refuerza la necesidad de Feature Engineering con variables de intención de compra.

¿Qué nos dice el ROC-AUC? Hacia la Optimización

Curva ROC (aproximación visual)



Conclusiones clave

ROC-AUC 0.626

RF discrimina mejor que el azar; estructura no lineal confirmada

LR $\approx$ azar

Ninguna frontera lineal separa las clases con utilidad

Umbral 0.50

Conservador: pierde 646 upgrades reales en cada ciclo

Prox. paso

Optimización de HPs + ajuste de umbral para maximizar Recall

Proceso Iterativo: v1 → v4 (de Grid a Búsqueda Aleatoria)



Cambio decisivo v4: Average Precision penaliza predecir todos como positivos (Recall trivial). ROC-AUC sube de 0.6146 → 0.6322; AP sube de ~0.64 → 0.6594. Próximo paso: Feature Engineering en v5.

v5: Feature Engineering — Construir Señal donde no Hay Variables

9 Proxies de Negocio Construidos

estimated_days_since_signup	Antigüedad estimada (LTV / ticket × 30d)
purchase_frequency_intensity	Frecuencia de compra / antigüedad ★
ticket_promedio_estimado	LTV / frecuencia de compra ★
marketing_efficiency	LTV / gasto de marketing
friction_free_customer	Binaria: sin tickets ni demoras
engagement_score	Visitas × páginas × tiempo de sesión
email_engagement	Open rate × click rate
spend_per_visit	Gasto total / visitas
value_per_ticket	LTV / tickets de soporte

Screening de 5 Conjuntos de Features

Feature Set	Vars.	ROC-AUC	Avg.Prec.
v5_best_screening ★	8	0.6323	0.6484
v5_core_business	10	0.6188	0.6364
v4_baseline (6 base)	6	0.6172	0.6372
v5_full_engineering	15	0.6161	0.6387
v5_all_original+eng.	28	0.6151	0.6432

Hallazgo clave

8 variables superan a 28. La parsimonia con significado de negocio gana sobre la dimensionalidad bruta. Las 2 features ganadoras (★) son las que normalizan comportamiento por la antigüedad del cliente

v5 final (tuning profundo sobre v5_best_screening): ROC-AUC = 0.6326 · Average Precision = 0.6629 · Objetivo ROC-AUC ≥ 0.75 no alcanzado
→ se necesitan variables temporales reales

Muchas Gracias